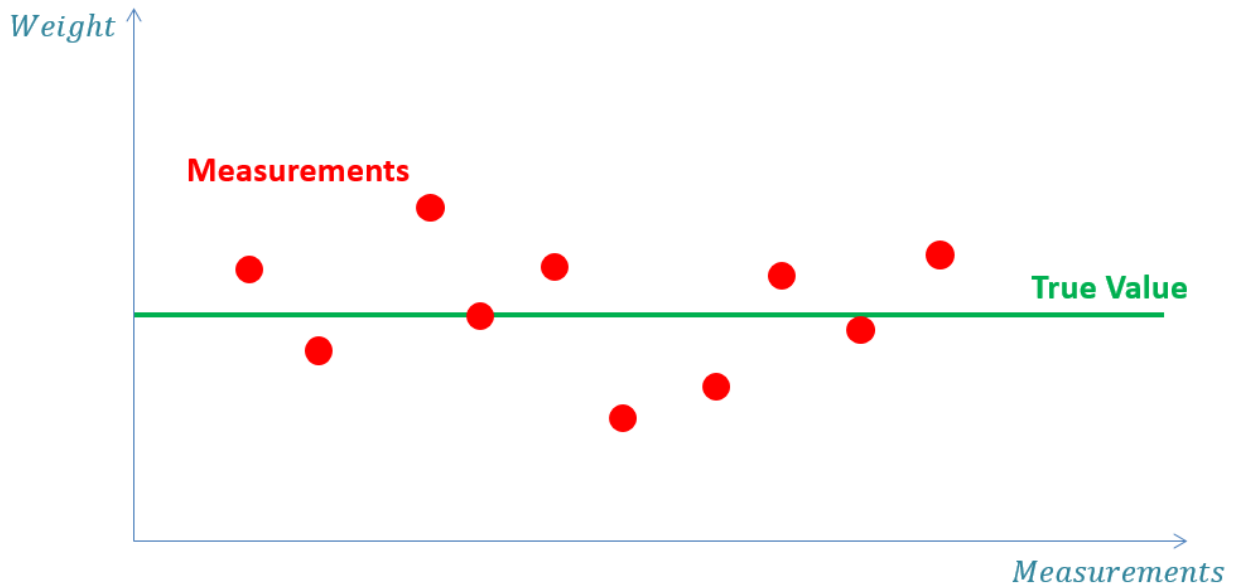


KalmanFilter

以一个例子开头：



假设我们需要对一个机器人的重量进行估计，我们可以通过机器人的大小，材质，以及实际的测量对一个机器人的重量进行估计，由于大小材质的估计难以准确，以及测量仪器的精度有限，我们无法得知真实的重量，只能得到一个自己的估计值以及测量值。经过多次测量我们得到如上的结果图，面对这种情况，我们为了获得一个更加精确的值，通常可以通过多次测量并求平均值来提高测量的准确性。

$$\hat{X}_n = \frac{1}{n}(Z_1 + Z_2 + \dots + Z_{n-1} + Z_n) = \text{Average}(\sum_{i=1}^n Z_i)$$

假如现在又获得了一个测量数据，为了利用上这个数据，我们可以使用如下的公式来更新估计值：

$$\hat{X}_{n+1} = \frac{Z_1 + \dots + Z_n + Z_{n+1}}{n+1} = \frac{n\hat{X}_n + Z_{n+1}}{n+1} = \hat{X}_n + \frac{1}{n+1}(Z_{n+1} - \hat{X}_n)$$

也就是:

$$\boxed{\text{The estimate of the current state}} = \boxed{\text{Predicted value of the current state}} + \boxed{\text{Factor}} \times \left(\boxed{\text{Measurement}} - \boxed{\text{Predicted value of the current state}} \right)$$

我们可以拓展一下整个过程:

估计:

- 我们先看到这个机器人,我们对重量有一个大致的估计值 \hat{X}_0
- 估计我们的估计值的误差为 σ_0

更新:

- 我们可以测量一次这个机器人的重量，得到测量值 Z_1
- 我们可以根据测量值 Z_1 更新我们的估计值 \hat{X}_1 (求平均)
- 我们可以根据测量值 Z_1 更新我们的估计值的误差 σ_1

不断重复更新

上面的过程只包含一次估计,然后就是不断更新,这其实是特例,或者也可以看成是我们在估计过程前后,我们的估计值没有发生变化,也就是估计过程是 $y = x$,估计值没有变化

或者我们可以这样想：

初始化:

- 假设我们先只看到了机器人，先对重量有个大致的估计值 \hat{X}_0
- 估计我们的估计值的误差为 σ_0

估计:

- 我们摸了摸机器人, 大致估计了部分机器人的材质, 对重量有个更加精确的估计值 \hat{X}_1^-
- 估计我们的估计值的误差为 σ_1^-

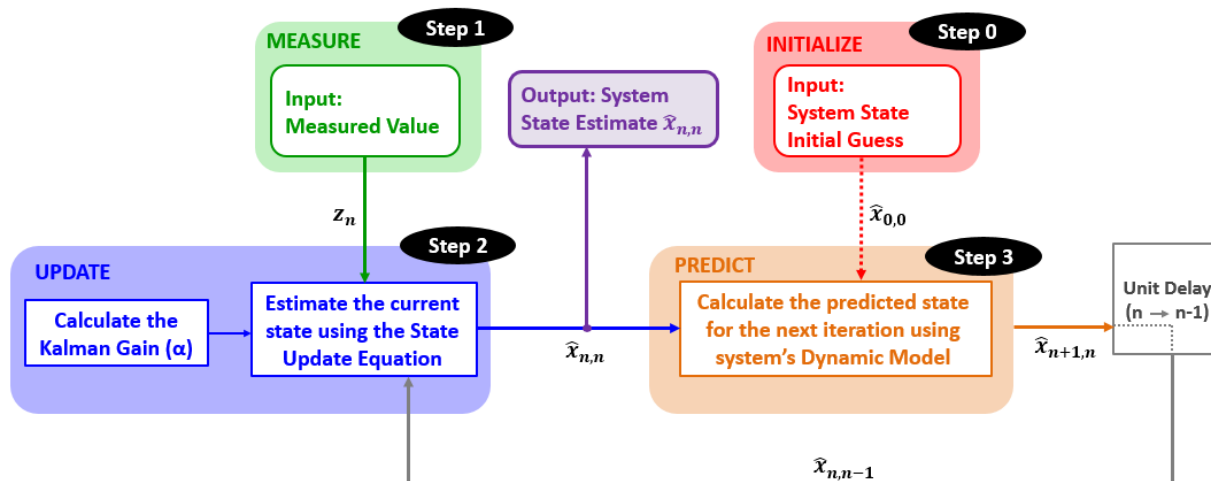
更新:

- 我们又称了称机器人, 得到测量值, 根据测量值 Z_1 更新估计值 \hat{X}_1
- 我们可以根据测量值 Z_1 更新我们的估计值的误差 σ_1

不断重复 估计,更新

这样的话, 我们的估计过程的估计值就是不断在更新的, 也就是估计过程是 $y = f(x)$, 估计值在不断变化
更新过程是测量值和估计值的比较

用图来全面展示一下:



其实这就是我们的kalman filter的过程, 我们先对状态进行估计, 然后通过测量值对估计值进行更新, 然后不断重复这个过程, 这样我们就可以得到一个更加精确的估计值。

kalman filter 黄金五式

预测:

$$\begin{aligned} \text{先验估计: } \hat{X}_k^- &= F\hat{X}_{k-1} + BU_{k-1} \\ \text{先验误差协方差: } P_k^- &= FP_{k-1}F^T + Q \end{aligned}$$

更新:

$$\begin{aligned} \text{卡尔曼增益: } K_k &= \frac{P_k^- H^T}{HP_k^- H^T + R} \\ \text{后验估计: } \hat{X}_k &= \hat{X}_k^- + K_k(Z_k - H\hat{X}_k^-) \\ \text{更新误差协方差: } P_k &= (I - K_k H)P_k^- \end{aligned}$$

初值: \hat{X}_0, P_0

F : 状态转移矩阵, B : 控制矩阵, U : 控制向量, Q : 过程噪声协方差矩阵, H : 观测矩阵, R : 观测噪声协方差矩阵, I : 单位矩阵

协方差矩阵: [参考bilibili Dr can](#)

协方差矩阵是一个用来描述多个变量之间关系的矩阵。你可以把它想象成一个表格, 每一行和每一列都代表一个变量, 每个单元格里面的数字就是两个变量之间的协方差。协方差是一个衡量两个变量的相似程度的指标, 它的正负和大小都有意义。如果协方差是正的, 说明两个变量是正相关的, 也就是说, 一个变量增大时, 另一个变量也会增大; 如果协方差是负的, 说明两个变量是负相关的, 也就是说, 一个变量增大时, 另一个变量会减小; 如果协方差是零, 说明两个变量没有线性关系, 也就是说, 一个变量的变化不会影响另一个变量的变化。协方差的绝对值越大, 说明两个变量的相关程度越强, 反之则越弱。

举个例子:

假设我们有三个变量, 分别是学生的数学成绩 X 、英语成绩 Y 和体育成绩 Z , 我们可以用一个 3×3 的协方差矩阵来表示它们之间的关系, 如下:

$$\begin{bmatrix} \text{cov}(X, X) & \text{cov}(X, Y) & \text{cov}(X, Z) \\ \text{cov}(Y, X) & \text{cov}(Y, Y) & \text{cov}(Y, Z) \\ \text{cov}(Z, X) & \text{cov}(Z, Y) & \text{cov}(Z, Z) \end{bmatrix}$$

- $cov(X, X)$ 就是数学成绩和数学成绩之间的协方差，也就是数学成绩的方差，它的值越大，说明学生的数学成绩越分散，也就是说，学生的数学成绩差异越大；
- $cov(X, Y)$ 就是数学成绩和英语成绩之间的协方差，它的值越大，说明学生的数学成绩和英语成绩之间的相关性越强，也就是说，学生的数学成绩和英语成绩越相似；
- $cov(X, Z)$ 就是数学成绩和体育成绩之间的协方差，它的值越大，说明学生的数学成绩和体育成绩之间的相关性越强，也就是说，学生的数学成绩和体育成绩越相似；以此类推。


其实kalman filter的过程就是一个数据融合的过程,我们把我们对这个过程的先验知识和测量值进行融合，得到一个更加精确的估计值。

因为物理真值不可能获得，所以我们只能通过测量值来估计物理真值，但是测量值又不是完全可靠的，所以我们需要对测量值进行修正，这就是kalman filter的过程。

Data fusion

Z_1 服从 a, σ_1 的正太分布, Z_2 服从 b, σ_2 的正太分布

估计真实取值： $\hat{Z} = Z_1 + K(Z_2 - Z_1)$ ，求得合适的K使得 \hat{Z} 的波动最小，即方差最小。



详情参考 Dr_can https://www.bilibili.com/video/BV12D4y1S7fU/?spm_id_from=333.788&vd_source=189e765254c924184e8a13b2384d02d2

以一个例子继续：

假设我们在估计一辆在平地上运动的车辆的状态，状态为 $x = [s, v]^T$, s 为车辆的位置， v 为车辆的速度，假设我们固定 dt 测量一次车辆的位置，我们可以得到如下的状态转移方程：

$$x_{k+1} = \begin{bmatrix} 1 & dt \\ 0 & 1 \end{bmatrix} x_k + w_k = Fx_k + Q$$

假设我们对汽车运动状态的估计是**匀速直线运动**，那么我们可以得到如下的状态转移方程， w_k 代表在第 k 个 dt 我们估计的运动状态和实际的误差，比如实际上汽车有加速度

我们用一个卫星测量这个汽车的位置，假设测量误差为 v_k ，那么我们可以得到如下的测量方程：

$$z_k = [1 \quad 0] x_k + v_k = Hx_k + R$$

我们可以得到如下的**协方差矩阵**：

$$Q = \begin{bmatrix} E(ss^T) & E(sv^T) \\ E(sv^T) & E(vv^T) \end{bmatrix}, R = var(v)$$

这些代表了我们对各个状态之间的相关性的估计，比如我们认为位置和速度之间的相关性为0，那么我们就把他们的协方差值设置为零，通常情况下我们都认为各个状态变量之间相互不相关

$$Q = \begin{bmatrix} \sigma_s^2 & 0 \\ 0 & \sigma_v^2 \end{bmatrix}, R = var(v)$$

也就是各个变量自己的方差

开始计算 具体过程查看excel, 密码是下面这个问题的答案:
假设 $Z_1 = 6.5mm, Z_2 = 7.3mm$, 我们假设已知 Z_1 的测量波动标准差为 $\sigma_1 = 0.2mm$, Z_2 的测量波动标准差为 $\sigma_2 = 0.4mm$, 求我们估计得到的最优值应该是多少?

简略推导(啥也没讲)

实际情况state space 方程：

$$\begin{aligned} X_k &= AX_{k-1} + BU_{k-1} + W_{k-1}(\text{过程噪声}) \\ Z_k &= HX_k + V_k(\text{测量噪声}) \end{aligned}$$

X_k : 第 k 次状态值, U_{k-1} : 第 $k-1$ 次的输入, W_{k-1} : 第 $k-1$ 次的过程噪声, Z_k : 第 k 次的观测取值, V_k : 第 k 次的测量噪声
假设 \mathbf{W}, \mathbf{V} 服从期望为 0 , 协方差矩阵为 \mathbf{Q} 和 \mathbf{R} 的正态分布, $cov(A) = E[AA^T]$ 。

$$\begin{aligned} \hat{X}_k^- &= AX_{k-1} + BU_{k-1} : \text{先验估计取值 (建模计算)} \\ \hat{X}_{kmea} &= H^- Z_k : \text{观测估计取值 (测量)} \end{aligned}$$

可以通过以下计算得到后验取值

$$\begin{aligned} \hat{X}_k &= \hat{X}_{k-1}^- + G(H^- Z_k - \hat{X}_{k-1}^-) \\ G &= K_k H \end{aligned}$$

目标：取 K_k 使得 \hat{X}_k 的误差最小，即 $e_k = X_k - \hat{X}_k$ 的误差最小， e_k 是服从期望为 0 , 协方差矩阵为 \mathbf{P} 的正太分布，所以就是 $P = E[ee^T]$ (协方差的定义式) 最小，而根据矩阵论的知识，可以知道 $tr(P)$ 最小就是 P 最小。

根据 \mathbf{P} 的定义式推导，带入已经知道的 e , 得到 $tr(p)$ 的表达式，再根据矩阵求导，对 K_k 求导，并令导数为零可以求得最后的 K_k 取值。

经过一系列推导可以求得当 K_k 取值如下时，可以获得最小的后验估计误差：

$$K_k = \frac{P_k^- H^T}{H P_k^- H^T + R}$$

其中, R : 观测误差的噪声, H : 观测矩阵, P_k^- : k 时刻的先验误差的协方差矩阵, $e_k^- = X_k - \hat{X}_k^-$: 先验误差 (先验估计值和实际取值之间的误差)。

$P_k^- = E[e_k^- e_k^{-T}]$ ，带入 e_k^- 通过推导，可以得到

$$\begin{aligned} P_k^- &= AE[e_{k-1} e_{k-1}^T] A^T + E[W_{k-1} W_{k-1}^T] \\ \text{即} P_k^- &= AP_{k-1} A^T + Q \end{aligned}$$

Extended Kalman Filter

Nonlinear Equation：

$$\begin{aligned} X_k &= f(X_{k-1}, U_{k-1}, W_{k-1}) \\ Z_k &= h(X_k, V_k) \end{aligned}$$

通过泰勒展开线性化，运用Kalman filter进行状态估计。由于系统存在各种误差，无法得知真实取值点，所以在 \hat{X}_{k-1} 处展开，线性化，即：

$$\begin{aligned} X_k &= f(\hat{X}_{k-1}, U_{k-1}, W_{k-1}) + A(X_k - \hat{X}_{k-1}) + WW_{k-1} \\ A &= \frac{\partial f}{\partial X} |_{X = \hat{X}_{k-1}, U = U_{k-1}} \\ W &= \frac{\partial f}{\partial W} |_{X = \hat{X}_{k-1}, U = U_{k-1}} \\ Z_k &= h(X_k, V_k) + H(X_k) \end{aligned}$$

预测：

$$\begin{aligned} \text{先验计算：} \hat{X}_k^- &= f(\hat{X}_{k-1}, U_{k-1}, W_{k-1}) \\ \text{先验误差协方差：} P_k^- &= AP_{k-1} A^T + WQW^T \end{aligned}$$

校正：

$$\text{卡尔曼增益} : K_k = \frac{P_k^- H^T}{H P_k^- H^T + V R V^T}$$

$$\text{后验估计} : \hat{X}_k = \hat{X}_k^- + K_k (Z_k - h(\hat{X}_k^-, V_k))$$

$$\text{更新误差协方差} : P_k = (I - K_k H) P_k^-$$